

A-2 Le connexionnisme

A-2-1 Spécificités connexionnistes

Il y a deux points principaux sur lesquels le paradigme connexionniste entend se distinguer du paradigme symbolique. Le premier est la prise en compte de la dimension neuronale de la cognition, et il le fait en proposant une modélisation du système cognitif dont l'allure générale est inspirée de la structure neuronale du cerveau. Le second point est de prendre en considération la dimension empirique des processus cognitifs, et plus précisément notre capacité à reconnaître ou à associer des formes, ou à manifester un savoir sans pouvoir expliciter les règles auxquelles il semble se conformer. Ces deux aspects de l'expérience, qui se concilient mal avec l'idée cognitiviste que la cognition consiste en une manipulation de symboles gouvernée par des systèmes de règles logiques, peuvent être rapportés, dans le cadre connexionniste, à une seule et même caractéristique des processus cognitifs, à savoir que ceux-ci reposent sur un mécanisme d'inférences statistiques qui se développe dans un système complexe formé d'un très grand nombre d'éléments non interprétables sémantiquement.

L'approche connexionniste de la cognition mise beaucoup sur les phases d'apprentissage. Elle conteste le découpage tranché entre sensation, perception, intellection, et la modularité qui caractérise les différentes études réalisées dans le cadre cognitiviste. Elle défend une application étendue du mécanisme de reconnaissance de formes. A l'idée qu'un objet est constitué par la conjonction de diverses informations recueillies par des modules spécialisés, le connexionnisme oppose la thèse d'une dynamique interactive impliquant les unités élémentaires du réseau cognitif et donnant lieu à l'émergence de formes. La thèse de l'émergence, et le mécanisme d'inférence statistique sur lequel elle repose, permettent d'accorder au contexte de la perception une légitimité théorique qui répond à la variabilité que révèle l'expérience. Pour rendre compte de cette variabilité, c'est ici encore la phase d'apprentissage qui fournit l'alternative à l'hypothèse de règles déterminées. Mais si l'apprentissage d'un réseau met en scène un instructeur, à quoi ou à qui revient ce rôle dans le cas d'un système cognitif naturel ? Quand ce n'est plus par le projet du modélisateur que sont définies les premières formes apprises, et établies les premières connexions, comment le sont-elles ?

Architecture Connexionniste

La publication en 1943, par Warren McCulloch et Walter Pitts¹⁰⁴, de l'article 'A logical calculus of the ideas immanent in nervous activity' témoigne déjà des deux préoccupations qui seront au cœur de l'approche connexionniste : d'une part, la description des processus cognitifs doit s'inspirer de notre connaissance du système nerveux, et d'autre part, il existe une capacité à traiter globalement des informations qui rend possible la reconnaissance de formes semblables. Les auteurs démontrent, en effet, qu'un réseau d'unités de calcul, opérant en parallèle, est capable de réaliser des opérations logiques :

A crucial aspect of their modelling was that the properties of the computing units were based on those of the neuron [...] Mc Culloch and Pitts showed that a network of neurons with these simple properties could compute any logical function. [...] First they showed that patterns of inter-neuronal connections could compute the logical functions AND, OR and NOT. Then they showed how a net of neurons computing these simple functions could be together to compute an elementary set of mental events¹⁰⁵.

Cette impulsion se retrouve dans la construction de réseaux d'unités élémentaires connectées entre elles à la manière d'un réseau de neurones, et susceptibles de produire des configurations globales d'activation. A la différence, cependant, des unités utilisées par Mc Culloch and Pitts, fonctionnant selon une loi du tout-ou-rien, l'état des unités connexionnistes peut varier continuellement à l'intérieur d'un certain domaine. En outre, tandis que Mc Culloch and Pitts utilisaient des connexions rigides, celles des réseaux connexionnistes peuvent être modifiées de manière à rendre compte des processus d'apprentissage. Enfin, la logique opérationnelle qui était à la base du réseau originel a laissé la place à des processus d'inférence statistiques.

Un réseau connexionniste sera ainsi constitué d'unités, ou nœuds, dotées d'un certain niveau d'activation, et les connexions qui les relient permettent que les unités activent ou inhibent les autres unités. Le processus cognitif de base peut être vu comme la production d'une certaine configuration d'activation, dite de sortie, par la propagation d'excitations et d'inhibitions parmi les unités du réseau lorsqu'une configuration d'activation est fournie au réseau en tant que configuration d'entrée. Pour comprendre ce qui est caractéristique des

¹⁰⁴ W. McCulloch and W. Pitts, A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5, 1943, pp.115-133 [Repris dans Anderson and Rosenfeld, 1998]

¹⁰⁵ P. McLeod, K. Plunket and E. Rolls (ed.), *Introduction to connectionist Modelling of Cognitive Processes*, Oxford: Oxford University Press, 1998, pp.314-318.

réseaux, le mieux est encore, selon Betchel¹⁰⁶, de comprendre leur mode de fonctionnement. Considérons alors un ensemble d'unités caractérisées par une certaine valeur d'activation et connectées entre elles. La manière dont les unités sont connectées entre elles joue un rôle déterminant dans le fonctionnement du réseau et le type de tâche qu'il peut réaliser. Un modèle simple est, par exemple, un réseau à propagation unidirectionnelle où les unités appartenant à la configuration d'activation d'entrée, les unités d'entrée, et les unités appartenant à la configuration d'activation de sortie, les unités de sortie, sont organisées en couches distinctes. L'activation se propage de la couche d'entrée à la couche de sortie, au travers éventuellement de couches intermédiaires, par l'intermédiaire de connexions, affectées d'un poids, reliant les unités de chaque couche. Le poids, ou la force, des connexions exprime l'intensité de la corrélation entre deux unités. Une règle d'activation spécifie la fonction reliant le niveau d'activation d'une unité (de sortie) et les différentes unités d'entrée associées à chaque connexion. La configuration de sortie qui est alors produite dépend, d'une part, des caractéristiques fonctionnelles des unités, comme leur mode d'activation, discret ou continu, leur seuil ou intervalle d'activation, et d'autre part des règles d'activation.

Des variantes plus complexes d'architectures sont obtenues lorsque les connexions ne sont pas unidirectionnelles ou que la propagation d'activation ne se fait pas simplement d'une couche vers une autre. On peut concevoir (Betchel, 1991, p.46) un schéma de connexions permettant aux unités d'une même couche d'envoyer des inhibitions ou des excitations les unes aux autres aussi bien qu'aux unités de la couche suivante. Et on peut ajouter encore à la complexité du processus en construisant des réseaux interactifs dans lesquels les connexions peuvent être bidirectionnelles. Dans ce cas, la propagation des excitations et inhibitions se fait de façon dynamique en mettant en œuvre un grand nombre de cycles constituant le processus de traitement de l'information d'entrée. Le retour d'information qu'induit le caractère bidirectionnel des connexions conduit, en effet, à une série de révisions des valeurs d'activation des unités dont le résultat dépend de leur seuil d'activation et de l'entrée qu'elles reçoivent. Le système finit par se stabiliser, c'est-à-dire qu'une configuration de sortie est obtenue, lorsqu'un état est atteint dans lequel aucune unité ne reçoit d'entrée produisant un changement de sa valeur d'activation.

Ce qui fait l'un des intérêts majeurs des systèmes connexionnistes est qu'ils peuvent être capable de modifier le poids des connexions, « *d'apprendre de l'expérience en changeant*

¹⁰⁶ W. Betchel and A. Abrahamsen, *Connectionism and the mind*, Oxford : Blackwell, 1991.

le poids des connexions » (Betchel, 1991, p.74). Etant donné un état arbitraire du système et une règle d'apprentissage déterminant les conditions de modification des forces de connexions, le système parvient de lui-même, à la suite de la présentation d'un ensemble de configurations, à établir une répartition des forces de connexions, un état de connectivité, qui satisfait aux exigences contenues dans la phase de présentation.

Un exemple classique de règle d'apprentissage de l'*association* de formes est celle que Hebb formula en imaginant que la connexion entre deux neurones est renforcée lorsque ceux-ci sont excités en même temps : le poids de la connexion entre deux unités est augmenté ou diminué selon que les unités sont actives simultanément ou pas, c'est-à-dire en fonction de la valeur prise par le produit de leur activation (McLeod et al., 1998, pp.54-58). Une procédure d'apprentissage pour un modèle à deux couches peut consister à présenter une série de couples de configurations, dont la seconde représente la configuration de sortie que le système doit 'apprendre' à associer à la première, dite d'entrée (par exemple, associer la vue du chocolat et le goût du chocolat, et associer la vue de l'abricot et le goût de l'abricot).

On trouve aussi dans McLeod (1998) un exemple détaillé de réseau autoassociatif formé avec la règle dite Delta, ou encore un réseau multicouches entraîné avec un algorithme de rétropropagation. Dans ce cas, les modifications des poids des connections se font de sorte à minimiser la différence entre la réponse du réseau et ce qui était attendu de lui. Le réseau apprend à *copier* en ayant le modèle qui agit comme un instructeur :

[T]he current connectionist strategy depends either on restricting the space of possible attractors by means of assumptions about the known properties of the world, which are incorporated as additional constraints for regularization, or in more recent models, on using back propagation methods where learning resembles the imitation of an external world. (Varela *et al.*, 1991, p. 148)

Analogie Neuronale

Nul ne doute que les systèmes connexionnistes aient plus d'affinité avec les systèmes neuronaux que n'en ont les systèmes symboliques. D'un côté, les défenseurs du paradigme symbolique, tels Fodor ou Pylyshyn¹⁰⁷, ne cherchent pas à produire une description des processus cognitifs en rapport avec les systèmes de neurones car la compréhension de ces processus ressortit exclusivement, selon eux, à des théories abstraites computationnelles capables de produire des modèles de syntaxe et de sémantique combinatoire : « *[M]ental*

¹⁰⁷ J.A. Fodor and Z.W.Pylyshyn, Connectionism and cognitive architecture: A critical analysis. *Cognition*, 28, 1988, 3-71.

representations characteristically exhibit a combinatorial constituent structure and a combinatorial semantics. » La cognition humaine, disent-ils, exhibe des propriétés particulières telles que la systématique et la productivité, qui sont aussi celles des langages naturels. Pour comprendre le processus cognitif, il faut donc le concevoir comme un système de manipulation syntaxique de représentations et c'est l'analyse du niveau de traitement symbolique qui est seule pertinente pour cette forme de théorisation ; or, ce niveau n'est pas connexionniste et en outre, le type de représentation requis pour une conception linguistique de la pensée n'est pas celui utilisé par les modèles connexionnistes. De l'autre, le modèle connexionniste a été pensé, dans son architecture et son fonctionnement, par analogie avec le système neuronal dans le but d'établir des ponts entre les conditions de possibilité physiques de la cognition et ses manifestations symboliques et empiriques. Car, l'une des lacunes immédiates des explications qui fondent les capacités cognitives sur l'existence d'un système linguistique de manipulation de représentations est qu'elles ignorent complètement la question de la réalisation, de l'incarnation des processus cognitifs : « *[I]t leaves unanswered the question of how such representations might be embodied in the mind*¹⁰⁸. » La capacité des réseaux à modifier les forces des connexions entre unités élémentaires lors de procédures d'apprentissage est censée fournir un équivalent des transformations qui affectent un système neuronal lors de l'acquisition de nouvelles connaissances. C'est d'ailleurs là, dans le rôle et la nature des connexions, que se trouve le point fort de l'analogie.

L'état d'un système connexionniste, et donc son fonctionnement, dépend, outre ses caractéristiques initiales, de l'histoire de son fonctionnement, des situations auxquelles il a été confronté. Le fonctionnement computationnel d'un système symbolique, au contraire, fait appel à des règles rigides, indifférentes à la diversité des cas traités et limitées en nombre. Dans le cas des systèmes connexionnistes, les procédures de transformations sont sous la dépendance d'informations locales, dans le sens où l'activation d'une unité dépend de ce qui se passe autour d'elle, de la force des connexions qui la rejoignent et des états d'activation des unités auxquelles elle se trouve reliée (même si elle peut, par la propagation de proche en proche, être aussi influencée par des événements éloignés). Cela signifie que l'activité du réseau n'est pas déterminée à l'avance, et de manière unique, déterminée par un quelconque agent extérieur, mais dépend, ponctuellement, de l'état de connectivité atteint par le système à l'issue de ses différentes situations d'apprentissage et du contexte particulier de la transformation.

¹⁰⁸ W. Betchel, *Representations : From Neural Systems to Cognitive Systems*. In Betchel *et al.* (eds), 2001, pp. 332-348.

Une connexion, même déterminée, ne représente pas une contrainte catégorique comme l'est une règle d'inférence logique opérant entre deux symboles. Une unité de sortie est, en effet, connectée à plusieurs autres unités, possédant chacune leur propre valeur d'activation ; la règle d'activation qui régit le calcul de la valeur d'activation de l'unité considérée combine pour cela les entrées associées aux différentes connexions. Il s'ensuit que les connexions prises individuellement ne sont pas déterminantes et que c'est la situation globale entourant une unité, avec ses diverses contraintes, qui peut produire l'activation ou l'inhibition de cette unité. La contrainte que représente chaque connexion n'est pas mesurable dans l'absolu mais dépend à chaque fois du contexte dans lequel elle intervient. La stabilisation du système traduit, selon les termes de Varela, l'émergence d'un état de mutuelle satisfaction entre les neurones : « *[T]here is a global cooperation that spontaneously emerges when the states of all participating 'neurons' reach a mutually satisfactory state.* » (Varela et al., 1991, p.88)

Toutefois, l'analogie neuronale, d'après Betchel (1991, p.66-67), ne va pas au delà de ces aspects généraux de la structure neuronale : il faut considérer, dit-il, la métaphore neuronale comme une source d'idée qui peut ou non être féconde, le soubassement biologique constituant un élément favorable mais non déterminant de son succès. Il n'en reste pas moins que l'attention à la structure neuronale est un élément distinctif majeur du connexionnisme par rapport au cognitivisme puisque celui-ci la considère 'hors sujet' tandis que celui-là en a abstrait sa formalisation. Le connexionnisme a mis en place, en s'inspirant des descriptions neuronales, un niveau de formalisation que P. Smolensky¹⁰⁹ qualifie de 'subsymbolique', intermédiaire entre le niveau de description neuronal et le niveau de description symbolique, à partir duquel les structures mentales n'interviennent que dans des descriptions approximatives. Pour comprendre plus précisément ce statut accordé aux structures mentales, et à la description symbolique, il faut aborder la question de l'interprétation sémantique de l'activité d'un réseau.

Interprétation Sémantique

Dans les systèmes symboliques, les règles sont employées dans la manipulation de symboles qui peuvent recevoir une interprétation sémantique ; ils peuvent, par exemple, être considérés comme les représentants de concepts. Les buts, les croyances, les connaissances,

¹⁰⁹ P. Smolensky, IA connexionniste, IA symbolique et cerveau. In *Introduction aux sciences cognitives*, sous la dir. de D. Andler, Paris : Gallimard, 1992, p.83.

sont formalisés sous la forme de structures symboliques dont la construction et la manipulation sont régies par un ensemble de principes logiques déterminés.

Dans les systèmes connexionnistes, il n'y a pas de règle logique ni de symbole. Les règles qui gouvernent la dynamique d'un réseau se manifestent dans la procédure de transmission des activations et dans la procédure de modification des forces de connexions. Or, les premières sont de nature non pas logique mais statistique : les contraintes que constituent les connexions sont des contraintes souples dans la mesure où c'est un ensemble de connexions qui est impliqué dans l'effet produit par l'activation de certaines unités sur une autre. Et quant aux procédures de modification, les éléments déterminants sont la règle d'apprentissage et les situations rencontrées par le système (par exemple les couples particuliers de configuration). La logique est ici encore recouverte par la particularité des cas : l'état de connectivité d'un réseau est indissociable de son architecture et de son histoire, et ces deux éléments sont des contraintes pour chaque nouvelle transformation.

Le niveau de description de la nature et du fonctionnement des règles connexionnistes est subsymbolique en ce sens que les entités concernées, le niveau d'activation des unités élémentaires et les forces de connexions ne sont pas interprétables sémantiquement : « *[D]ans le paradigme symbolique la description du système formel se situe à un niveau inférieur à celui de l'interprétation sémantique ; le niveau de la dénotation est plus élevé que le niveau de la manipulation.* » (Smolensky, 1991, p.86) Quel est le niveau de la dénotation ? C'est celui auquel se forme les configurations d'activation. L'entité qui reçoit ici une interprétation sémantique est un ensemble d'unités, associées chacune à un certain niveau d'activation et reliées entre elles par des connexions, associées chacune à un certain poids. Pour qualifier cette délocalisation de la valeur sémantique, on parle de 'représentations distribuées'. C'est ce niveau supérieur, où émergent les configurations, qui est mis en rapport avec les structures mentales. Mais identifier ces entités complexes à des symboles manipulés par des règles logiques correspond pour le connexionniste à une description grossière qui n'a de valeur qu'approximative.

Il y a une autre façon que par des inférences logiques de mettre en relation les configurations, et qui reste fidèle aux particularités de fonctionnement des réseaux connexionnistes : c'est d'assimiler les configurations à des unités. Il est possible alors de considérer que la dynamique du niveau supérieur est gouvernée par des lois formelles du même type que celles du niveau subsymbolique, et qui sont des inférences statistiques et non pas logiques. Smolensky, qui défend ce point de vue, admet que dans des conditions idéales de résolution d'un problème, le comportement qui émerge au niveau supérieur peut être décrit en

termes d'inférences logiques ; mais il souligne que « *si l'on sort de ces conditions idéales, l'illusion en vertu de laquelle le système contiendrait des contraintes dures s'évanouit rapidement.* »

Reconnaissance de Formes

Ce que l'on désigne par 'forme' pour un système cognitif est une structure complexe possédant une unité distinctive, et éventuellement une valeur sémantique. Dans le contexte connexionniste, une forme est associée à une configuration d'activation, et mettre en correspondance deux formes signifie établir un état de connectivité tel que l'activation d'une certaine configuration induise systématiquement l'activation d'une autre configuration particulière. C'est ce qui se produit, par exemple, lorsque à la suite de la présentation d'une série de couples de configurations, le système met en place une répartition des poids de connexions telle que, par la suite, la présentation de l'une des configurations d'entrée est suivie de la réalisation de la configuration qui lui était associée. La capacité de reconnaissance de forme recouvre, en fait, nombre d'aptitudes cognitives caractérisées par différentes sortes de mise en correspondance de formes. Betchel (1991, p.115) propose les distinctions suivantes :

- « *la mise en correspondance d'une forme spécifique avec une forme plus générale* », qui permet les actes de catégorisation, classification, généralisation, identifiant un individu comme élément d'un ensemble défini par une forme générale ;
- la mise en correspondance « *d'une forme incomplète avec une version complète de la même forme* », mise en œuvre dans les actes d'anticipation utilisant une expérience antérieure ou les actes de remémoration à partir de certains éléments servant d'indices ;
- la mise en correspondance « *d'une forme avec une forme différente qui lui est liée* », comme dans le cas de mots différents désignant les formes composées d'un même verbe ;
- et enfin, « *la mise en correspondance arbitraire d'une forme avec une autre sans lien avec elle* », comme dans les actes de nomination associant une forme résultant d'une perception visuelle (un objet) et d'une perception auditive (un nom).

Le problème que résout la capacité à reconnaître des formes est que des événements distincts doivent être apparentés sans pourtant n'être jamais identiques. Ce qui caractérise un

système connexionniste, c'est le caractère statistique des inférences, la souplesse des contraintes. Du fait que les unités sont reliées par une pluralité de connexions et que les configurations expriment la satisfaction *optimale* d'un ensemble de contraintes, les activations ou inhibitions qui traduisent une incomplétude ou une déformation de la configuration d'entrée par rapport à une configuration de référence sont compensées par les effets d'interaction ou de rétro-propagation qui conduisent le système vers un état stabilisé. Le même type de processus d'ajustement est mis en œuvre pour la complétion, l'association ou la transformation de formes car la complétion d'une forme peut être vue comme la réalisation d'une configuration de sortie, ou bien la réalisation d'une configuration de sortie peut être vue, à un niveau de description supérieur, comme la complétion de la configuration d'entrée.

Il a pu sembler jusqu'à présent qu'une frontière assez nette séparait les conceptions symboliques et connexionnistes du fait de la différence de nature bien marquée de leur modèles de référence et de leurs instruments conceptuels, l'ordinateur, la logique, la computation, les symboles, d'une part, les réseaux, l'inférence statistique, la dynamique, l'émergence de forme, d'autre part. Et il est d'ailleurs tentant de voir dans l'interprétation des contraintes déterminant la constitution des formes le lieu de cristallisation de la divergence entre les approches computationnelle et dynamique du fonctionnement d'un réseau : l'approche computationnelle doit faire référence à des contraintes extérieures au système, tandis que l'approche dynamique reste dans l'immanence du réseau. La distinction pourtant se fait plus floue lorsque l'on se rend compte que le schème 'computo-représentationnel' n'est pas la propriété exclusive du paradigme symbolique. Un système connexionniste est même, selon Cummins & Schwarz¹¹⁰, en règle générale, computationnel et représentationnel, dans le sens où « *il passe de façon réglée d'un état représentationnel à l'autre* ». Cela signifie que les configurations d'activation peuvent être considérées comme des représentations et que le système peut apprendre à modifier les poids des connexions de manière à ce que les transformations de configurations satisfassent certaines règles ou ensemble de règles assimilables à des fonctions cognitives. De ce point de vue, le développement et le fonctionnement du système cognitif sont essentiellement déterminés par des contraintes qui lui sont extérieures, les contraintes épistémologiques relatives à chaque domaine de la connaissance.

Selon Smolensky, ce qui marque de façon plus significative la divergence des approches connexionnistes et cognitivistes est le type d'instrument mathématique qu'elles

¹¹⁰ R. Cummins & G. Schwartz, 1992, p.386.

utilisent¹¹¹ : tandis que le paradigme symbolique utilise une mathématique discrète et développe un traitement séquentiel des processus cognitifs, le paradigme connexionniste utilise une mathématique continue pour calculer les variations qui se produisent en parallèle sur l'ensemble du réseau.

Description Dynamique

L'utilisation par les connexionnistes d'une mathématique continue exprime l'abandon de la 'métaphore de l'esprit comme l'ordinateur'. La mathématique discrète du paradigme symbolique représente les processus cognitifs comme des transformations séquentielles d'une structure déterminée en une autre selon des règles universelles. Les opérations de traitement de l'information relient des entités atemporelles et déterminées par des règles atemporelles et déterminées. Lorsque le système cognitif est considéré comme un système dynamique, il est caractérisé par un ensemble de variables continues (les valeurs d'activation, les forces de connexions) et de contraintes (taille du réseau, seuils ou intervalles de variation des variables, règles d'apprentissage ou d'activation) ; son évolution est gouvernée par un système d'équations différentielles qui formalisent les variations interactives des différentes variables ; et l'instauration d'une configuration d'activation traduit la convergence du système d'équations vers une solution stable répondant aux conditions initiales posées. Vue de cette façon, l'intelligence perd beaucoup de son caractère exceptionnel pour rejoindre une classe extrêmement diversifiée de phénomènes naturels : celle des phénomènes dynamiques¹¹².

Mais si cette dualité d'approche mathématique est difficilement contestable, le rattachement du connexionnisme est, en revanche, controversé. Précisément, parce qu'ainsi que le remarquait Cummins, il est resté, dans sa forme classique, attaché aux hypothèses computationalistes du modèle symbolique, qui sont entièrement rejetées par l'approche dynamique : « *[M]any connectionists models have continued the static tradition of dealing with time*¹¹³. » Le connexionnisme, tout en prétendant prendre en considération la composante

¹¹¹ P. Smolensky, On the Proper Treatment of Consciousness, *Behavioral and Brain Sciences*, 11, 1988. Repris dans C. McDonald & G. McDonald, (1995), pp.28-89.

¹¹² J.A.S.Kelso, *Dynamic Patterns: The Self-Organization of Brain and Behavior*, MIT Press, 1995; R.F.Port & T. van Gelder (eds), *Mind as Motion:Exploration in the Dynamics of Cognition*, MIT Press, 1995.

¹¹³ R. Port, F. Cummins & J. McAuley, Naive Time, Temporal Patterns, and Human Audition. In R.F.Port & T. van Gelder (eds), 1995, p.349.

physique et la composante empirique de la cognition, néglige pourtant parfois un élément essentiel à l'une et à l'autre de ces composantes, c'est la dimension temporelle :

Much standard connectionist work (e.g., modeling with layered backprop networks) is just a variation on computationalism, substituting activation patterns for symbols. This kind of connectionism took some steps in the right direction, but mostly failed to take the needed leap *out* of the computational mindset and *into* time. The alternative must be an approach of cognition which *begins* from the assumption that cognitive processes happen in time. *Real* time. (R.Port & van Gelder, 1995, p.3)

L'instrument dynamique rend possible des modèles qui spécifient l'évolution du système pendant deux instants arbitrairement proches et peuvent rendre compte également d'une évolution discrète. Selon R.Port & van Gelder, seule une description continue de l'évolution du système cognitif permet de rendre compte des aptitudes qui requièrent de la flexibilité et du discernement dans le choix des comportements à adopter. Comme dans le cas des situations de coordinations sensori-motrices dans un environnement infiniment diversifié : « *[A] system which can flexibly deal with such a world must be able to occupy states that are equally rich and subtly distinct* »; ou encore, lorsqu'un mot du langage ordinaire peut apparaître dans différents contextes et y avoir des significations très légèrement différentes : « *[O]nly a system that can occupy a continuum of states with respect to word meanings stands a real chance of success.* »

C'est par contraste avec les approches dynamiques de la cognition, auxquelles il a quand même ouvert la voie, et plus spécialement par contraste avec les conceptions non représentationnistes que l'instrument dynamique autorise, que le connexionnisme se voit accusé de conservatisme. La conception développée par F. Varela sous le nom d'énaction s'appuie en effet sur l'idée « *que ce que nous appelons communément une représentation n'indique pas une correspondance entre ce qui se passe à l'intérieur du système et un certain état du monde extérieur, mais plutôt une certaine cohérence du système dans la façon dont il maintient continuellement son identité.*¹¹⁴ » L'usage théorique du concept de représentation encore à l'œuvre dans le connexionnisme traditionnel présente la connaissance comme la réalisation d'une relation entre un système cognitif (structure mentale ou connexionniste) et un objet autre que lui, doté de certaines propriétés. Cette relation de représentation est pensée comme une sorte de réflexion de l'objet dans le système cognitif qui constituerait le produit de l'activité cognitive : « *[U]ne entité cognitive est pour l'essentiel parachutée dans un monde*

¹¹⁴ F.Varela, *Autonomie et connaissance, Essai sur le vivant*, Paris : Editions du Seuil, 1989, p.11.

*préexistant. Cette entité n'y survivra qu'à la condition de posséder une carte et d'apprendre à agir en fonction de celle-ci.*¹¹⁵ » Pour une approche représentationniste, cognitiviste ou connexionniste, le critère d'évaluation de la cognition est la représentation, la reproduction adéquate d'un monde extérieur au système et prédéterminé. On parle alors d'informations correspondant à des propriétés du monde (les formes, les couleurs...) et de résolutions de problèmes bien définis posé par un monde indépendant du système.

Parler de représentations, dans ce sens, suppose que l'on considère les deux côtés d'une frontière délimitant un système cognitif par rapport à son environnement et que l'on établisse une relation entre un objet déterminé, à connaître, c'est-à-dire à représenter, et un autre objet, produit par le système, considéré comme la connaissance du premier. Mais, *« nous ne pouvons nous exclure du monde pour comparer son contenu avec ses représentations : nous sommes toujours immergés dans ce monde. »* (F.Varela, 1996, p.98) En outre, le schéma représentationniste ne permet pas de rendre compte du caractère autonome des êtres vivants, et de leur système cognitif, et doit passer sous silence le rôle prépondérant du sens commun constamment requis, et toujours de façon contextuelle, pour *« configurer notre monde d'objets »* : *« le contexte et le sens commun sont en fait l'essence même de la cognition créatrice. »* (F.Varela, 1996, p.98) Toutes les descriptions que nous pouvons énoncer le sont à partir d'une situation qui est seulement la nôtre et dont la particularité doit être prise en considération pour ce qu'elle est, avec son corps, sa biologie, son langage, ect.. Et notre conception de la cognition elle-même est un acte cognitif, et en tant que telle, elle est indissociable non seulement de la structure de notre système cognitif mais encore de la façon dont cette structure est sollicitée, perturbée, et gère les perturbations qui menacent l'unité du système, voire de l'être tout entier. Non seulement, un système qui n'est pas affecté dans son mode d'être n'a aucune connaissance de son environnement, et aucune connaissance du tout, mais encore, la connaissance n'est rien au-delà d'une certaine manière d'être affecté.

Je voudrais dans la suite étudier plus précisément la façon dont le connexionnisme a contesté le paradigme symbolique en utilisant le concept d'émergence pour décrire certains aspects fondamentaux de la connaissance, et essayer de mettre en lumière le moment de la description où se trouve mise en œuvre l'hypothèse représentationniste. Mon intention est de cerner au plus près la raison pour laquelle cette hypothèse a été rejetée par l'approche éactive et la façon dont celle-ci a fait de l'émergence la notion clé d'une conception non représentationniste.

¹¹⁵ F. Varela, *Invitation aux sciences cognitives*, Paris : Editions du Seuil, 1996, p.101.

A-2-2 La cognition sous l'éclairage connexionniste

L'émergence d'un niveau logique

L'acte de penser est comme environné d'une nimbe. Son essence, sa logique, représente un ordre, et particulièrement l'ordre *a priori* du monde... Cet ordre doit être *suprêmement simple*. Il est avant toute expérience : nulle perturbation, nulle incertitude empiriques ne doivent l'affecter. Il doit être plutôt du cristal du plus pur. [...] Nous sommes dans l'illusion que ce qui constitue le caractère particulier, profond, essentiel pour nous, de notre investigation, résiderait dans le fait qu'elle s'efforce de comprendre l'essence incomparable du langage. C'est-à-dire l'ordre qui existe entre les concepts de proposition, de mot, de conclusion, de vérité, d'expérience, ect¹¹⁶.

Le paradigme symbolique semble particulièrement bien adapté à la modélisation de nos aptitudes langagière, et de façon générale, notre capacité à exercer des savoirs qui semblent reposer sur la connaissance de règles précises. Mais, bien entendu, ceux qui défendent une approche connexionniste pense que ce paradigme-ci peut ou pourra rendre compte de manière plus satisfaisante de nos expériences cognitives. Puisque l'activité des réseaux connexionnistes consiste à mettre en correspondance des configurations, il faut donc que cette mise en correspondance soit au fondement de nos capacités cognitives, et que les réseaux la réalise de manière particulièrement intéressante. Que la mise en correspondance de formes est fondamentale pour nos activités cognitives, Betchel (1991, p.115) le soutient en distinguant, ainsi que nous l'avons vu précédemment, quatre types de correspondance pouvant servir de schèmes interprétatifs :

- la mise en correspondance d'une forme spécifique avec une forme générale : c'est la reconnaissance de formes proprement dite ;
- la mise en correspondance d'une forme incomplète avec une version complétée : c'est la complétion de formes ;
- la mise en correspondance d'une forme avec une forme différente qui lui est liée : c'est la transformation de formes ;
- la mise en correspondance arbitraire d'une forme avec une autre : c'est l'association de formes.

¹¹⁶ L.Wittgenstein, *Investigations Philosophiques*, St Amand : Gallimard, 1961, §97.

Quel est, maintenant, l'intérêt spécifique du traitement connexionniste ?

L'activité d'un réseau repose sur l'existence de connexions reliant les unités les unes avec les autres. En dehors des phases d'apprentissage, pendant lesquelles les connections sont établies, cette activité est conditionnée par l'état de connectivité du réseau. En ce sens, les connexions constituent pour l'activité d'un réseau une contrainte comparable aux règles logiques stipulées par le paradigme symbolique. Mais il y a une différence essentielle : l'inférence connexionniste n'est pas logique mais statistique. Les connexions sont des *contraintes souples* : du fait que les unités sont reliées par un grand nombre de connexions, aucune d'entre elles n'est déterminante à elle seule ; c'est seulement des connexions qui est mise en jeu dans la propagation qui détermine la réalisation d'un état stable particulier du réseau. Autrement dit, la condition qui détermine la réalisation d'une configuration est une contrainte *globale* qui implique les différents modes d'organisation accessibles au système dynamique que constitue le réseau. Une contrainte globale, et non pas générale, cela veut dire que ce n'est pas une règle extérieure, qui préexisterait au système lui-même et à son histoire, qui serait indépendante de son contexte d'application. La règle de type connexionniste est immanente au système : elle dépend à la fois de son histoire, *via* les procédures d'apprentissage, et de sa situation actuelle, car des activations peuvent se propager entre régions éloignées et impliquer des éléments contextuels.

C'est cette souplesse de la règle connexionniste qui peut permettre de rendre compte de l'aptitude à suivre une règle dans certaines conditions, et d'y faire exception dans d'autres. Et c'est ce rôle déterminant joué par le contexte dans le fonctionnement du réseau qui fait dire à Smolensky que le système subsymbolique du connexionnisme est au système symbolique du cognitivisme ce qu'un système quantique est à un système newtonien : « *un système possédant au niveau micro des contraintes souples, satisfaites en parallèles, paraît, au niveau macro avoir, dans les circonstances favorables, des contraintes dures satisfaites séquentiellement. Mais en réalité, ce n'est pas vrai, si l'on sort de domaine 'newtonien', on voit que ce n'a en fait pas cessé d'être un système quantique.* » (Smolensky, 1992, p.95) C'est une illusion de penser que la réalisation d'actes cognitifs qui semblent suivre une règle logique doit être *fondée* sur l'existence d'une règle logique. La modélisation connexionniste conduit à distinguer ce qui apparaît au niveau conceptuel de la manipulation symbolique et ce qui se produit au niveau sub-conceptuel des unités sub-symboliques. Dans certains cas, l'activité du réseau au niveau conceptuel peut être vue comme régie par des règles déterminées. Mais l'activité du réseau au niveau sub-symbolique est celle d'un système dynamique et repose sur la satisfaction globale

d'un ensemble de contraintes souples. Dans le cadre du connexionnisme, le niveau de la computation symbolique émerge du niveau de la computation sub-symbolique : ce qui est identifié comme structure symbolique au niveau conceptuel est un état limite du système dynamique sub-conceptuel évoluant continuellement selon un ensemble d'équations différentielles.

Knowing How, Knowing That

L'analyse classique de la capacité d'expertise proposée par Dreyfus¹¹⁷ fournit une application concrète de ce qui vient d'être dit en mettant en évidence une distinction entre 'savoir que', 'knowing that' et 'savoir comment', knowing how' déjà soulignée par Wittgenstein : « *Savoir ou comprendre quelque chose n'est pas du type d'un knowing that, d'un savoir que, mais d'un knowing how, d'un savoir comment. Ce n'est pas une connaissance propositionnelle mais une aptitude pratique. [...] Une aptitude mentale ou une capacité ... est l'expression du fait que l'agent a subi un apprentissage ... qu'il a suivi certaines règles [...] [S]uivre une règle est une pratique que l'on acquiert dans le contexte d'un jeu de langage public...¹¹⁸* »

Le cas du joueur d'échec tient une place paradigmatique dans la démonstration de Dreyfus que l'expertise est un savoir-faire qui n'est pas un savoir propositionnel, c'est-à-dire que la connaissance à laquelle parvient l'expert fait de celui-ci quelqu'un qui sait ce qu'il faut faire (dans chaque situation) sans qu'il puisse dire pourquoi c'est comme cela qu'il faut faire. L'acquisition d'un savoir d'expert est décomposée en cinq étapes, depuis le 'novice', qui apprend des règles générales indépendantes des contextes, auxquelles il obéit aveuglément, et l'élève compétent capable d'adopter un plan qui structure son analyse des situations, d'évaluer les paramètres pertinents, d'inventer de nouvelles règles, jusqu'à l'expert, qui, ayant été confronté à un « *très grand nombre de situations variées, toutes perçues dans la même perspective, mais appelant des décisions tactiques différentes* », en est arrivé « *à décomposer cette classe de situations en sous-classes, dont chacune relève ... d'une même tactique particulière.* » Pour chaque situation ainsi discriminée, et le nombre en est immense, l'expert connaît le type approprié de réponse et « *ce qui est à faire, de manière transparente, est fait.* »

Dreyfus insiste sur l'idée que ce que reconnaît l'expert, ce à quoi répondent ses choix, ne sont pas, comme Herbert Simon le prétend, des éléments particuliers, des éléments choisis

¹¹⁷ H.L.Dreyfus, La portée philosophique du connexionnisme. In Andler (dir), 1992.

¹¹⁸ P. Engel, *Philosophie et psychologie*, Paris : Gallimard, Folio, 1996, p.172-173.

parmi ceux constituant une situation. C'est une situation globale située dans une perspective d'ensemble de la pratique qui est déterminante. Le joueur d'échecs n'opère pas en fonction d'une configuration prise par un groupe de pièces car il se peut que la même configuration dans des situations différentes appelle des réponses différentes, ou que des configurations différentes doivent être traitées d'une manière semblable. La perspective cognitiviste envisage certaines figures de pièces comme des symboles identifiables car elle cherche à formuler « *les relations entre éléments objectifs non contextuels en termes de principes abstraits.* » Mais le sens des figures de pièces, de même que dans le cas du langage les significations, change avec le contexte. La théorie symboliste « ne peut pas expliquer pourquoi, à des occasions différentes d'emploi d'un symbole, il peut y avoir une variation significative dans les référents visés ». En outre, l'interprétation de Simon recourt à l'existence « *d'une règle de production pour un grand nombre de positions et d'une seconde règle permettant de calculer la ressemblance, en sorte que chaque position puisse être traitée comme identique à celle à laquelle elle ressemble le plus.* » Mais une telle démarche de modélisation a l'inconvénient majeur de négliger le fait que l'expert n'a pas de « *connaissance introspective de règle permettant de calculer la ressemblance.* »

Le modèle connexionniste est bien mieux adapté que le modèle symboliste pour expliquer les processus investis dans le savoir d'expert que Dreyfus a décrit car celui-ci ne repose pas sur la connaissance explicite de règles rigides, et qu'il est extrêmement sensible aux aspects contextuels des situations. L'expert, en tant que novice, a commencé par apprendre des règles générales, puis il a franchi par lui-même la distance séparant ce stade de celui de l'expertise en produisant, sur la base de son expérience, en étant confronté à de nouvelles situations, d'autres règles. Ces dernières, à la différence de précédentes, s'inscrivent dans une démarche qui lui est propre, un projet, un but à atteindre. C'est de la rencontre entre l'intention du joueur et les diverses situations qu'ont émergé de nouvelles règles consistant à agir d'une certaine façon dans certaines situations. Ce n'est pas la production d'une règle générale, qui serait appliquée à une infinité de cas particuliers ; de même que Wittgenstein montrait que la signification n'est pas une règle générale qui gouvernerait l'usage des mots, indépendamment de leur contextes d'occurrence, comme s'il y avait « *une idée générale de la feuille qui ne comprendrait que des éléments communs à toutes les feuilles.* » L'idée de l'existence d'une règle générale se traduit, dans le cas du joueur d'échecs, par la théorie de Simon selon laquelle nous posséderions en mémoire des figures particulières d'ensemble de pièces, des *chunks*, auxquels nous comparerions les figures particulières rencontrées dans une partie, et qui

détermineraient notre réaction. Dans le cas du langage, ce sont les figures du monde, des choses, des situations, que nous confronterions à notre forme générale pour déterminer quel est l'acte de langage qui convient.

Selon Dreyfus, l'expert s'est inventé des règles au fur et à mesure des situations qu'il a abordé dans une perspective personnelle ; c'est cette implication personnelle dans la pratique qui donne aux situations et à la façon dont il y répond, une signification, une valeur, qui lui permet de les mémoriser. Les situations sont ensuite reconnues sans qu'il faille se référer à un modèle général par l'intermédiaire d'une règle de comparaison ; le processus de comparaison est en quelque sorte immanent aux formes en question. L'expert fait simplement ce qu'il doit faire, en fonction des situations. Posséder un concept, écrit Cavell, comme lorsque nous continuons une série sur la base d'un nombre limité d'exemples, ce n'est pas pouvoir énoncer une règle, « *c'est être capable de poursuivre avec ce mot dans de nouveaux contextes [...] je connais la série, je pense continuer avec un mot, lorsque pour moi, la continuité va de soi*¹¹⁹. »

La capacité d'expertise que décrit Dreyfus s'accorde bien avec une conception connexionniste des capacités cognitives. Les performances manifestes de l'expert émergent d'un niveau tacite de la connaissance constitué par l'incorporation des expériences d'apprentissage. Mais cet accord n'a d'intérêt que si le comportement de l'expert correspond à la description qui en est faite. Or c'est précisément en s'appuyant sur la notion de comportement émergent que B. Hendricks-Jansen¹²⁰ critique la position de Dreyfus en mettant en question la notion de comportement planifié ou structuré par une relation entre fin et moyens.

A-2-3 Description d'une action : Deux conceptions de l'émergence

La perspective de l'agent

L'interprétation selon laquelle une séquence d'opérations serait structurée par un plan déterminé qui, conscient ou pas, n'aurait qu'à être appliqué, ne correspond pas, selon Hendricks-Jansen, à la manière dont nous réalisons des plans, effectivement, au quotidien. Cela vaut peut-être pour les premiers stades d'une pratique, tant que l'apprenti suit des règles apprises, mais ce que nous désignons par 'action' désigne un comportement qui est

¹¹⁹ S. Cavell, *Les voix de la raison*, Paris : Ed. du Seuil, 1979, p.194 ;

¹²⁰ B. Hendricks-Jansen, *Catching Ourselves in the act : Situated Activity*, Cambridge, MA : MIT Press, 1996.

incompatible avec l'existence d'un plan déterminé. La notion d'émergence servira ici à désigner le caractère tout à la fois orienté et imprévisible de l'action : « *What is required is a view of development that imposes no limits on the potential flexibility and context sensitivity of behavior but also renders it susceptible to deliberate shaping* » (Hendricks-Jansen, 1996, p.306) C'est le double aspect d'effectivité et de flexibilité de l'action qui doit ressortir de la conception émergente: les plans que nous réalisons en acte ne précèdent pas les séquences d'actes, ils se déterminent, en général, au fur et à mesure de la séquence en cours, en fonction de son déroulement. L'orientation que prend un enchaînement d'actes résulte, émerge, d'un processus d'interaction entre notre action et le milieu sur ou dans lequel nous agissons. L'apprenti de Dreyfus a commencé à agir en appliquant quelques règles simples, ces premières actions ont instauré un processus d'interaction avec un certain milieu, et de ce processus émerge un espace de mouvement évolutif dont les caractéristiques sont co-constituées, en continu, par les actions effectuées et les résistances rencontrées, et selon lesquelles se poursuit la dynamique interactive.

Ce qui apparaît ici comme essentiel est la distinction entre le point de vue de l'observateur d'un comportement et celui de l'agent lui-même, ou plutôt celui du mouvement en train de se faire : le découpage d'un comportement en éléments reliés logiquement les uns aux autres ressortit au point de vue de l'observateur, « *but this does not mean that the creature itself performs acts or decides between alternatives acts.* » L'approche par l'extérieur, qui découpe un comportement en parties distinctes et articulées entre elles, est associée par P. Ricoeur à un type de théorie de l'action qui focalise la discussion sur la question de savoir ce qui vaut comme action parmi les événements du monde. La démarche suivie consiste à chercher les réponses au couple de question *quoi ? pourquoi ?*: « *[A]fin de déterminer ce qui vaut comme action, on a en effet cherché dans le mode d'explication de l'action le critère même de ce qui mérite d'être décrit comme action.*¹²¹ » Face à cette attitude, Ricoeur dénonce l'occultation de la question concernant le *qui ?* de l'action et entreprend la recherche d'une perspective sur l'action qui soit apte à prendre en charge les trois dimensions de l'interrogation. La difficulté de la recherche est de cerner l'agent qui respecte « *la nécessité de conjoindre le qui ? au quoi ? et au pourquoi ? de l'action ... [nécessité] issue de la structure d'intersignification du réseau conceptuel de l'action.* » (Ricoeur, 1990, p.133)

¹²¹ P. Ricoeur, *Soi-même comme un autre*, Paris: Ed. du Seuil, 1990, p.78.

Organisation de l'activité

A la description séquentielle d'un comportement, H. Hendricks-Jansen oppose l'idée d'une « *organisation de l'activité émergeant d'une interaction* » : pas de plan général, pas de décision ni de représentation interne, mais des attitudes qui sont cohérentes entre elles et adaptées au contexte parce que, précisément, le comportement général est, à chaque instant, déterminé à la fois par l'histoire du comportement et les conditions présentes du contexte. La dualité entre description séquentielle et interprétation émergentiste du comportement semble faire écho à celle soulignée par Smolensky entre description symbolique et interprétation émergentiste de l'activité d'un réseau connexionniste. N'avons-nous pas dit que les configurations émergeaient au niveau conceptuel d'une dynamique sub-symbolique interactive conditionnée aussi bien par l'histoire que par la situation contextuelle du système ? Et d'ailleurs, I Stengers, dans son parcours interdisciplinaire des processus émergents reconnaît à la modélisation néo-connexionniste une place quasi-paradigmatique¹²².

Il y a, selon F. Varela, deux formes d'usages du concept d'émergence qu'il est essentiel de bien distinguer : « *[E]n mettant en valeur l'acquisition par un réseau d'une faculté bien spécifique dans un domaine défini, on retrouve le principe de la représentation habituelle* », tandis qu'« *en insistant sur le fait qu'un processus historique fait émerger des régularités sans contraintes de finalité arrêtée, on conserve la notion biologique d'un monde non circonscrit.* » Cette distinction a donc une conséquence épistémologique très importante. Du point de vue de Smolensky, remarque Varela, la connaissance est pensée en référence à un monde possédant des propriétés prédéfinies, « *l'objectif est de trouver une activité endogène qui corresponde à la caractérisation optimale du milieu* » (Varela, 1996, p.117). Ou encore, comme le souligne Stengers, l'activité d'un réseau connexionniste n'est pas envisageable indépendamment des intentions de son fabricant et de ce que ce fabricant considère comme étant une connaissance valable. Dans le cas d'une reconnaissance de forme, la forme à reconnaître, disons 'B', et les formes jugées comme ressemblantes sont définies en fonction de ce que nous connaissons : « *Il s'agit de faire coïncider de manière optimale le 'bassin attracteur' de toutes les configurations initiales qui mènent à un même comportement et l'ensemble de toutes les configurations initiales qui, pour nous, sont des 'B'.* » (Stengers, 1996, p.83) Il est attendu du réseau qu'il reproduise notre connaissance.

¹²² I. Stengers, *Cosmopolitiques. Tome 6. La vie et l'artifice : visages de l'émergence*. Paris : La découverte, 1997, p.80-86.

Le rôle joué par l'émergence dans la pensée de Hendricks-Jansen participe du second usage distingué par Varela, et son approche n'est pas sans affinité avec le privilège accordée à la singularité plutôt qu'à l'optimalité qui caractérise ce que Stengers appelle la « modélisation de terrain » :

[L]e comportement des fourmis est un exemple maître d'efficacité, et il semble appeler l'attribution d'une valeur adaptative optimale. Si l'on suppose un optimum, on peut toujours le construire, mais si on ne le suppose pas, d'autres questions se posent, qui impliquent de 'suivre' l'émergence du comportement collectif à partir de la manière dont les interactions entre fourmis 'modulent' (et non déterminent) le comportement de chacune. La question est alors de comprendre l'efficacité, non de l'identifier à un optimum dont le comportement individuel serait déductible. [...] Les 'fourmis' au sens générique, multispécifique, pourraient alors célébrer l'invention d'un agencement entre individus et collectifs 'créateur de variantes significatives' . (Stengers, 1996, p.119-120)

Dans le second usage, le contenu de connaissance qu'exprime un comportement est une création, il n'est pas la copie de quoi que soit de prédéfini ; sa détermination est indissociable de la pratique par laquelle il est produit. L'idée qu'un comportement est l'expression d'une connaissance et l'idée que ce comportement prend place dans une chaîne causale d'événements appartiennent à la même perspective: c'est celle d'un observateur extérieur faisant une lecture sémantique de ce qu'il observe. Mais ce mode de lecture du comportement ne peut pas rendre compte de la flexibilité des comportements. Cette flexibilité vient justement de ce que le comportement n'est pas déterminé par une connaissance du monde insensible à la diversité des contextes et des contraintes spécifiques à un agent particulier. C'est parce que l'organisation de l'activité s'invente dans l'émergence, en continu, que les comportements apparaissent comme flexibles. Le mystère de l'adaptation à la diversité de l'environnement est engendré par la perspective sémantique, le point de vue extérieur et désengagé sur l'agent, qui regarde deux entités déterminées, le monde, aux visages innombrables, et l'agent, et se demande comment elles peuvent s'accorder. Lorsque l'émergence est une invention sans 'contrainte de finalité arrêtée', les visages du monde ne sont pas plus variés que l'interaction le permet puisque c'est elle-même qui les *constitue*.

Hendricks-Jansen prend pour illustrer son propos l'exemple du robot de Mataric : le déplacement du robot se différencie selon qu'il rencontre un mur ou un coin et semble ainsi disposer de deux comportements distincts adaptés à deux situations distinctes et reconnues comme telles. Mais le robot ne possède pas de représentations internes de chaque situation : « *It is true that its land-marks are identified in terms of correspondences between its own*

movments and its sensory inputs in response of specific features. However, the occurrence of such correspondences must be sought not in formal characteristics of behavioural components but in the fact that the robot's low-level reflexes have been calibrated to a particular environment.» L'activité du robot s'invente dans la rencontre entre l'organisation que constitue le robot et un environnement qu'il explore d'une manière qui lui est particulière, au sein duquel, par là-même, il se fait un milieu – un environnement qui n'est pas 'en soi' une source de problèmes déterminés, prédéfinis, pour lesquels existerait une réponse optimale. C'est cette rencontre qu'il faut suivre, dans le temps où elle se déroule, le temps vrai pour reprendre l'expression de van Gelder, le temps vrai de l'action, au lieu de chercher à modéliser une représentation de l'environnement tel que peut le décrire l'observateur, tel qu'il fait sens pour lui, bien après que la rencontre ait eu lieu.

A-2-4 Temporalité de l'action

Le défaut majeur des descriptions de l'action en terme de relation causale est, d'après Hendricks-Jansen, non seulement de ne pas rendre compte de la flexibilité de l'organisation de notre activité, mais surtout, si cette flexibilité suppose l'absence de représentation et de plan d'action déterminés, contrairement à ce que requiert la structure causale d'une séquence d'actes, de ne pas pouvoir en rendre compte. Du point de vue de P. Ricoeur, c'est son incapacité à intégrer la dimension temporelle de l'action qui marque les limites de ce type de description, et à deux titres. Le second, qui sera envisagé un peu plus tard, est relatif à l'ipséité et à la continuité temporelle qui la sous-tend. Dans l'immédiat, disons que c'est la subordination du caractère intentionnel de l'action à une conception causale de l'explication qui entraîne l'occultation de la temporalité.

L'importance accordée à l'intentionnalité par P. Ricoeur peut sembler situer sa recherche aux antipodes de celle de Hendricks-Jansen qui s'autorisait l'exemple d'un robot pour illustrer et appuyer son discours. Ce n'est pas le cas, car toute la finesse de l'argumentation de Ricoeur consiste à souligner la distinction entre 'intention dans laquelle' et 'intention de', et 'l'intention de' peut trouver place dans un schéma d'émergence tandis que 'l'intention dans laquelle' caractérise une lecture causale. Il pourrait sembler aussi que la temporalité attachée à l'intentionnalité, en tant que 'référence explicite au futur', doive empêcher de penser la flexibilité dans la mesure où celle-ci désigne l'inscription de l'agir dans le moment présent. Mais là encore, la distinction soulignée par Ricoeur va libérer le futur des déterminations imposées par la réduction de l'intentionnalité à la seule 'intention dans laquelle'. Et c'est cette

restauration de l'ouverture des possibles qui permet de redonner au moment présent toute la puissance créatrice que suppose la flexibilité et que Port & van Gelder (1995) tiennent pour indissociables de la continuité temporelle des processus cognitifs.

Intentionnalité de l'action

La critique de l'analyse causale de l'action prend pour cible caractéristique la théorie de Davidson¹²³ « où le couple des questions *Quoi ?* et *Pourquoi ?* se voit aspiré dans une ontologie de l'événement impersonnel qui fait de l'action elle-même une sous-classe d'événements. » (Ricoeur, 1990, p.93) C'est l'intention qui distingue l'action des autres événements ; mais l'intentionnalité est là une réponse au *Pourquoi ?* et s'insère dans un schéma causaliste en s'exprimant de façon adverbiale¹²⁴ : en « *traitant l'intention comme un adverbe, il est possible de la subordonner à la description de l'action en tant qu'elle est un événement échu.* » Les actions sont posées là-devant, en tant qu'éléments d'une classe d'événements parmi les événements du monde, elles constituent en quelque sorte les nœuds d'un tissu de relations logiques offert à la curiosité d'un observateur. L'explication ne fait à aucun moment appel à un agent incarné, car la liaison du *Quoi ?* au *Pourquoi ?* signifie que les actions sont identifiées seulement par leur relation à d'autres événements, des raisons (« *raisons et actions sont bien des événements par leur caractère d'incidence* »), et les événements ont le statut d'objets.

P. Ricoeur conteste que l'on soit justifié à négliger l'usage substantif de l'intention (l'intention de). Il y a des traits originaux de l'intention, absents de l'usage adverbial, et qui pourtant correspondent à certains aspects de notre expérience de l'agir, étant liés au fait que l'intention n'est pas forcément séparable du déroulement de l'action. L' 'intention de' introduit un délai par lequel se découvre « *non seulement le caractère d'anticipation, de visée à vide de l'intention, [...] mais le caractère projectif de la condition même de l'agent.* » L'anticipation ne signifie pas la représentation d'un événement mais, tout à la fois, l'orientation vers le futur et la continuité de l'activité, qui sont dissimulées par une description distanciée et séquentielle. Contrairement à l'idée de l'existence de représentations ou d'une 'intention dans laquelle', l' 'intention de' accompagne l'activité de telle sorte que chacune se nourrit de l'autre ; l'intention n'est pas figée, et le caractère anticipatif n'introduit pas la rupture, la séparation entre un acte et

¹²³ D. Davidson, *Essays on actions and events*, Oxford : Clarendon Press, 1980.

¹²⁴ « 'l'intention dans laquelle' étant tenue pour une simple extension discursive de l'adverbe 'intentionnellement' » p.94.

son résultat qui est inhérente à la description séquentielle et causale. L'anticipation exprime la dimension interactive de l'organisation de l'activité en restaurant la dynamique temporelle déployée par l'action. De plus, l' 'intention de' renvoie nécessairement à un agent, impliqué par, impliqué dans l'action, et qui était complètement occulté par le primat du Pourquoi ? dans la description objective.

Il est important de souligner que la focalisation sur le présent de l'action, sur son déroulement, et sur un agent impliqué dans la réalisation et l'organisation de son activité, qui caractérise les interprétations de H. Hendricks-Jansen et de P. Ricoeur, n'interdit pas l'interprétation que ces auteurs critiquent mais la complète. En effet, tandis que P. Ricoeur va imposer à son agent qu'il respecte « *la structure d'intersignification du réseau conceptuel de l'action* », H. Hendricks-Jansen reconnaît que « *an intentional description of our behavior cannot provide clues to the underlying mechanisms of that behavior, but they are essential to our ability to learn new skill* » (l'intentionnalité est ici celle désignée par les philosophies analytiques, l'intention dans laquelle). La même remarque vaut au sujet de l'interprétation énaïve proposée par F.J.Varela, qu'il justifie par l'insatisfaction suscitée par « *l'absence de sens commun dans la définition de la cognition jusqu'à ce jour* », mais en ajoutant que « *chacune de ces approches (représentationniste et énaïve) est utile dans son propre contexte* ». Ce point vaut d'être remarqué car, si les approches participatives autorisent les approches objectivistes, distanciées, l'inverse n'est pas vrai. Et c'est précisément, me semble-t-il, ce qui fait la faiblesse de ces dernières. L'approche objectiviste ne nie pas qu'il y ait un agent de l'action, mais celui-ci peut être omis de la description dès lors que l'affirmation de l'existence de représentations internes ou l'usage de la forme adverbiale de l'intentionnalité font de cette description une explication causale.

La démarche alternative que développent ceux qui ont le souci du "sens commun" n'exclut pas les explications 'désengagées', parce qu'appréhender l'action en prenant en considération, ou même, en tenant pour essentiel le rapport de l'action à son agent ce n'est justement pas produire une explication alternative au sens d'exclusive, c'est plutôt ouvrir une nouvelle perspective. L'agent introduit bien une dimension nouvelle au sein de l'analyse causale car la dépendance de l'action vis-à-vis de l'agent n'est rien d'autre que l'expression d'un pouvoir-faire primitif: « *la puissance de l'agent doit être tenue en dernière instance pour primitive* ». Mais tout l'enjeu de la réflexion de P. Ricoeur est alors de concilier cet arrêt brutal sur l'agent dont le pouvoir d'agir est un fait primitif qui répond à la question sur le Qui? de l'action et l'ouverture de la chaîne des réponses au couple Quoi ?-Pourquoi?

Corporéité de l'action

Il faut pouvoir concilier le fait que, d'une part, le pouvoir d'agir fasse de l'action une *causa sui*, introduise la réalité absolue d'un être-qui-agit, et d'autre part, que l'action en tant qu'événement prenne place au sein d'un enchaînement causal qui décrit le cours du monde. P.Ricoeur avance l'idée que la structure même de l'action implique la conjonction des causalités si on la conçoit en tant qu' « *intervention de l'agent de l'action dans le cours du monde qui cause effectivement des changements* ». Comment l'action peut-elle être une « intervention », se trouver à la jonction de deux ordres de réalité? Le corps rend possible l'articulation; le corps en tant qu'il est un corps propre, qu'il appartient à l'univers des choses et à celui du soi. Le corps est à la fois ex-pression immédiate du pouvoir d'agir, et en tant que tel est constitutif d'un soi, et aussi inscription de ce pouvoir d'agir, et du soi, dans une action constituant un événement du monde. C'est en cela que la réflexion de P.Ricoeur peut être située dans le prolongement de la pensée de H. Hendricks-Jansen. L'action est irréductible à un événement et le pouvoir d'agir est une réalité absolue. En outre, l'agir est une interaction et une émergence: l'être pensé comme être-qui-agit suppose un monde: « *pas de soi sans un monde praticable en quelque façon* »; et le monde s'enracine dans l'agir: « *pas de monde sans un soi qui s'y trouve et qui agit* ». C'est la double appartenance du corps qui doit permettre de comprendre l'émergence au tant qu'elle traduit l'inscription de l'agir dans le monde et l'être-dans-le-monde du soi.

Cette charge que P. Ricoeur impose à sa recherche, de comprendre le pouvoir d'agir comme signifiant être soi et être du monde, comprendre le corps comme réalisant l'articulation entre l'être-soi et l'être-dans-le-monde, pèse aussi sur la théorie éactive proposée par Varela, qui fera l'objet de la Troisième partie. Le vocabulaire certes, est d'un autre registre; mais il n'est pas difficile de percevoir les correspondances entre les deux démarches. Je voudrais conclure ce bref parcours du texte de P.Ricoeur en repérant certains thèmes profondément partagés par ces deux formes d'étude apparemment si différentes de la manière dont nous habitons le monde.

Identité de l'Agent

La place essentielle reconnue au corps propre dirige l'interrogation sur ce « *qui spécifie le soi impliqué dans le pouvoir faire* ». Il a déjà été noté que la dimension temporelle était un élément essentiel de l'action dès lors que celle-ci était envisagée dans son rapport à un agent,

que ce soit en terme de flexibilité ou d'anticipation. Ici intervient l'autre aspect de la temporalité, seulement mentionné précédemment, pour constituer un élément tout aussi essentiel de la détermination de l'ipséité, mais en négatif de la forme sous laquelle nous l'avons auparavant perçue. C'est maintenant la continuité attachée au soi qui doit être considérée et qui se manifeste comme le revers de la flexibilité de l'agent, car il a bien fallu qu'on lui attribue silencieusement une permanence dans le temps pour qualifier de flexibles les manifestations de son pouvoir d'agir. La nécessité de penser une permanence qui traverse les changements inhérents à la condition d'être-qui-agit, qui est celle du soi, une permanence comparable à « *la structure de l'outil dont on aura progressivement changé toutes les pièces* », ou au bateau de Neurath, P. Ricoeur la désigne comme « *la quête d'un invariant relationnel* ». Mais cette forme de permanence ne suffit manifestement pas, l'exemple de l'outil le montre, à distinguer l'ipséité de la mêmeté.

Non qu'il faille en appeler à un dualisme des substances; la réponse faite par P.Ricoeur à la thèse de D. Parfit en témoigne. Parfit soutient que l'identité d'une personne consiste simplement dans l'occurrence d'une série d'événements qui peuvent être décrits de manière impersonnelle. Et il oppose cette thèse à la croyance que l'identité personnelle est constituée par « *un fait séparé supplémentaire* ». Mais affirmer l'irréductibilité du corps propre à un corps quelconque, c'est contester la réduction de l'identité à un ensemble d'événements impersonnels mais pas nécessairement invoquer un fait séparé; car il n'y a de fait séparé que par rapport à l'ontologie de l'événement. Or justement, la perspective du soi s'est introduite comme une tentative de pallier l'insuffisance de cette ontologie.

Le soi n'est pas quelque 'chose' qui se rajoute au tableau de la description impersonnelle; c'est une autre perspective sur le corps rendue possible par le fait que le corps n'est pas seulement un corps quelconque mais un corps propre. Mais sur quoi se fonde cette affirmation que le corps n'est pas seulement un corps quelconque? Cela ne se fonde sur rien, ou disons, pas sur quelque 'chose', mais rend compte d'une expérience, d'un vécu, sans pour autant que ce vécu soit érigé en fondement. Parler d'une expérience du corps qui n'est pas celle d'un corps quelconque n'implique pas que l'on élève le discours sur le corps propre au rang de Vérité, au contraire même, car le corps propre est le « *point d'ancrage* » de la perspective, il est « *l'organe d'un sujet qui n'appartient pas aux objets dont il parle.* » Affirmer l'irréductibilité du corps propre, c'est affirmer aussi qu'il n'est jamais objet de discours parce qu'il est « *la limite du monde et non un de ses contenus* », et aussi parce que « *l'étrange constitution du corps propre s'étend du sujet de l'énonciation à l'acte même d'énonciation: en tant que voix poussée au*

dehors par le souffle et articulée par la phonation et toute la gestuelle, l'énonciation partage le sort des corps matériels ».

L'effort d'être soi

Si l'invariant relationnel ne suffit pas à distinguer ipséité et mêmeté, il va quand même constituer un trait permettant d'intégrer ce qui a été dit du pouvoir d'agir à la caractérisation de l'ipséité. En qualifiant le pouvoir d'agir de 'fait primitif', P. Ricoeur a désigné une tension entre l'effectivité et la puissance qui lui paraît essentielle à l'agir humain. Cependant, il insiste pour inscrire cette tension sur un fond de réalité plus profonde dont l'agir humain ne serait qu'une forme de manifestation particulièrement « lisible ». Le caractère primordial de cette tension est appréhendé par référence à l'ontologie aristotélicienne et aux places qu'y occupent les concepts d'«acte» et de «puissance», à la fois respectivement, et relativement l'un à l'autre: les déterminations de l'acte et de la puissance s'appellent l'une l'autre, mais leurs champs d'application occupent les positions extrêmes de la chaîne des êtres. Et en plus, une réappropriation de l'ontologie aristotélicienne doit aussi prendre en charge le primat de l'acte qui s'en dégage, non seulement sur la puissance mais sur la substance.

C'est dans la philosophie de Spinoza que P. Ricoeur trouve une pensée du soi respectueuse de ces exigences, au travers de l'idée de *conatus*. Le *conatus*, « *en tant qu'effort pour persévérer dans l'être, qui fait l'unité de l'homme comme de tout individu* », et la puissance, qui "ne veut pas dire potentialité mais productivité", permettent de comprendre l'invariant relationnel et le pouvoir d'agir primitif, en comprenant l'invariant relationnel comme l'unité résultant d'une puissance toujours déjà actualisée à un certain degré. L'agir humain doit être pensé comme une manifestation de l'effort pour persévérer dans l'être, pour maintenir l'unité et en même temps comme l'expression de cette unité elle-même, et l'invariant relationnel devient une relation que le *conatus*, la puissance d'agir primordiale, essentielle à l'être, maintient invariante: « *la puissance d'une chose quelconque, ou l'effort (...) par lequel une chose s'efforce de persévérer dans son être n'est rien en dehors de l'essence donnée ou actuelle de la chose* ».

Il y a trois traits essentiels du «soi» mis en évidence par P. Ricoeur et qui me semblent tenir dans la théorie éactive une place primordiale: le pouvoir d'agir est un fait primitif, il existe un invariant relationnel définissant une unité, le corps propre est la limite du monde ; en se souvenant que le pouvoir, la puissance d'agir est toujours déjà en acte, investie dans le maintien de l'unité de l'être et constitutive de cette unité, et que le corps pâtit de ce qui s'oppose à cet effort et menace son unité.

L'énaction

Une conception de la connaissance plus attentive aux conditions de possibilité d'«un monde» implique une réflexion épistémologique qui tente de concevoir la relation d'interaction entre un système et le milieu dans lequel il évolue, et par laquelle émergent des comportements et sont constitués des objets. Pour comprendre la relation d'interaction, il faut préciser la nature du système qui la provoque, et le travail de P. Ricoeur est sous-tendu par la conviction que la caractérisation du comportement ne peut pas se faire sans penser l'identité de l'agent de l'action.

L'identité de l'agent ne désigne pas la détermination d'un sujet qui découvre le monde; un tel sujet, P. Ricoeur le souligne, est l'un des objets du monde 'à venir'. L'identité de agent désigne ici le «soi», ce qui antérieur à toute détermination, une condition de possibilité de l'ensemble des objets qui formeront pour l'agent, en tant qu'être situé quelque part, un monde, une condition de possibilité de la connaissance.

La théorie cognitive développée par F.J. Varela se distingue des interprétations connexionnistes par sa capacité à intégrer ces considérations sur le soi, en tant qu'être-qui agit et être-qui-connaît. C'est parce que la perspective épistémologique adoptée « *se préoccupe spécialement de faire prédominer le concept de l'action sur celui de la représentation* » qu'elle a été désignée par le terme d'énaction. Un usage représentationniste des systèmes connexionnistes essaie de décrire la façon dont sont reconnues des formes situées dans l'environnement du système. La théorie énative abandonne le présupposé d'un environnement prédéfini; le point de vue adopté est celui d'un système formant une unité qui interagit avec un environnement dont la détermination, la mise en forme, est le produit de processus essentiels au maintien de l'organisation constitutive de cette unité. Ces processus seront qualifiés de cognitifs par référence à l'émergence de formes incorporées résultant de l'interaction, et non par référence à une capacité de reproduction d'un donné indépendant. Le concept d'organisation prend ici la place de l'invariant relationnel pointé par P. Ricoeur pour désigner l'existence d'une unité. Le fait primitif que constitue la puissance d'agir investie dans le maintien de cette organisation, puissance entendue, précisait P. Ricoeur, comme productivité et non pas seulement comme potentialité, sera désigné par le concept d'autonomie.

Un système autonome est caractérisé par l'existence d'une dynamique constitutive d'une relation d'interaction invariante entre différents éléments participant de la réalisation d'une unité. Mais un système autonome n'est pas un système isolé, c'est au contraire un système qui

est nécessairement couplé au milieu dans lequel il se trouve et qui 's'efforce' de maintenir son organisation malgré les perturbations occasionnées par la relation qu'il entretient avec son environnement.

Tant que le connexionnisme présente les configurations exhibées par le réseau, c'est-à-dire les formes qui constitueront le contenu de la connaissance, comme des formes qui émergent de la dynamique du réseau en tant que solutions satisfaisant une exigence de cohérence interne, il n'est pas incompatible avec une théorie énaactive. Par contre, c'est un gouffre qui s'installe au sujet de l'interprétation de ces formes émergentes ou des perturbations qui forcent le système à changer de mode d'organisation. On peut bien considérer que, de même que l'on apprend à un réseau à reconnaître certaines formes particulière, l'évolution est un apprentissage par lequel un système cognitif a appris à reconnaître des formes déterminées en raison de l'avantage absolu que cela représente pour le maintien d'une espèce. Et considérer que les perturbations sont porteuses d'informations déterminées sur l'environnement et que les configurations de niveau supérieur représentent ces informations. Mais c'est un point de vue aveugle aux conditions inhérentes au corps propre.

La position résolument non représentationniste qu'incarne la théorie énaactive rejette l'idée que l'environnement contient des informations et que l'évolution s'apparente à un procès d'instruction. Que le corps propre, le soi, doivent être pensés comme des conditions de possibilité de la connaissance, en tant qu'ils désignent un lieu d'«ancrage», position non substituable à partir de laquelle le monde prend forme, cela veut dire que ce que l'on appelle 'environnement' du système cognitif doit être pensé seulement comme une source de perturbations pour la cohérence interne du système : *« [N]ous ne pouvons pas sortir du domaine spécifié par notre corps et notre système nerveux [...] nous ne pouvons pas remonter, d'une manière unique les traces d'une expérience donnée jusqu'à son commencement. »* (Varela et al., 1991)

A-3 Sur le débat entre réductionnistes et éliminativistes

A-3-1 Le cadre du débat

En quels termes et faisant référence à quoi doit s'écrire une psychologie scientifique ? Quelles sortes de descriptions doit-elle employer dans ses explications ? Le débat entre réductionniste et éliminativisme qui surgit lorsqu'il s'agit de répondre à ce genre de questions